

# Soutenance du Projet 2 Analysez des données de systèmes éducatifs

**Par** Elisée TCHANA

> **Mentor** Cyril MONTI



## Plan de Soutenance

Problématique et Présentation du jeu de données Analyse pré-exploratoire du jeu de données et Conclusions sur la pertinence de l'usage du jeu de données pour répondre aux questions stratégiques que se pose l'entreprise

Questions-réponses



# **Objectifs du Projet**

# **Objectifs**

Cibler les pays à fort potentiel pour une implantation Academy EdTech

Observer les potentielles évolutions de ces pays

Déterminer dans quels pays opérer en priorité



# Hypothèse du Projet

- 1. Valider la qualité de ce jeu de données (comporte-t-il beaucoup de données manquantes, dupliquées ?)
- 2. Décrire les informations contenues dans le jeu de données (nombre de colonnes ? nombre de lignes ?)
- 3. Sélectionner les informations qui semblent pertinentes pour répondre à la problématique (quelles sont les colonnes contenant des informations qui peuvent être utiles pour répondre à la problématique de l'entreprise ?)
- 4. Déterminer des ordres de grandeurs des indicateurs statistiques classiques pour les différentes zones géographiques et pays du monde (moyenne/médiane/écart-type par pays et par continent ou bloc géographique)

#### **Problématique**

Expansion à l'international pour une Startup de la Edtech

# CentraleSupélec UNIVERSITÉ PARIS-SACLAY

# **Data Analysis Workflow**







# Informations contenues dans le jeu de données (Pays, Indicateurs, Années)

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975		2060	2065	2070	2075	2080	2085	20
0	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2	NaN	NaN	NaN	NaN	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN	N
1	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2.F	NaN	NaN	NaN	NaN	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN	N
2	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN	١
3	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2.M	NaN	NaN	NaN	NaN	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN	N
4	Arab World	ARB	Adjusted net enrolment rate, primary, both sex	SE.PRM.TENR	54.822121	54.894138	56.209438	57.267109	57.991138	59.36554	11.7	NaN	NaN	NaN	NaN	NaN	NaN	١

4000 indicateurs internationaux décrivant l'accès à l'éducation

Caractéristiques de la base de données: 886930 lignes 70 colonnes

242 pays différents 3665 indicateurs différents



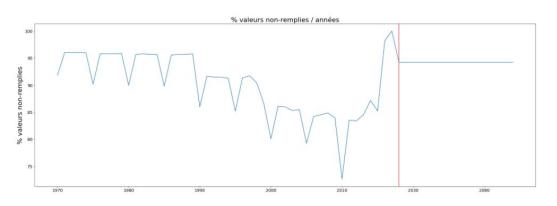
```
Adjusted net enrolment rate, lower secondary, both sexes (%)
Adjusted net enrolment rate, lower secondary, female (%)
Adjusted net enrolment rate, lower secondary, gender parity index (GPI)
Adjusted net enrolment rate, lower secondary, male (%)
Adjusted net enrolment rate, primary, both sexes (%)
Adjusted net enrolment rate, primary, female (%)
Adjusted net enrolment rate, primary, gender parity index (GPI)
Adjusted net enrolment rate, primary, male (%)
Adjusted net enrolment rate, upper secondary, both sexes (%)
Adjusted net enrolment rate, upper secondary, female (%)
Adjusted net enrolment rate, upper secondary, gender parity index (GPI)
Adjusted net enrolment rate, upper secondary, male (%)
Adjusted net intake rate to Grade 1 of primary education, both sexes (%)
Adjusted net intake rate to Grade 1 of primary education, female (%)
Adjusted net intake rate to Grade 1 of primary education, gender parity index (GPI)
Adjusted net intake rate to Grade 1 of primary education, male (%)
Adult illiterate population, 15+ years, % female
Adult illiterate population, 15+ years, both sexes (number)
Adult illiterate population, 15+ years, female (number)
```

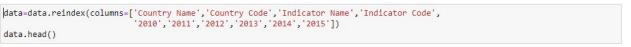


# Nettoyage des données



L'ensemble de données contient 95% de "nan" par années mais une diminution vers 2000





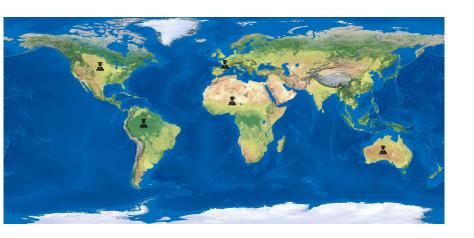
	Country Name	<b>Country Code</b>	Indicator Name	Indicator Code	2010	2011	2012	2013	2014	2015
0	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2	NaN	NaN	NaN	NaN	NaN	NaN
1	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2.F	NaN	NaN	NaN	NaN	NaN	NaN
2	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	NaN	NaN
3	Arab World	ARB	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2.M	NaN	NaN	NaN	NaN	NaN	NaN
4	Arab World	ARB	Adjusted net enrolment rate, primary, both sex	SE.PRM.TENR	85.211998	85.24514	86.101669	85.51194	85.320152	NaN

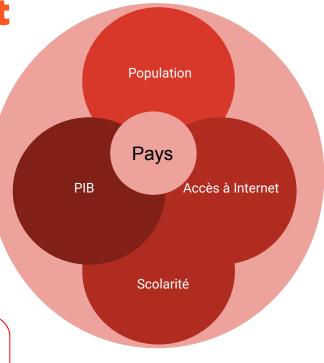
Notre analyse s'est porté sur une décennie récente sur une durée de Cinq ans. Cette décennie nous aide à définir une meilleure stratégie pour la Edtech

4000 indicateurs internationaux



Indice de développement





GDP per capita (current

US\$)

60% Gross enrolment ratio,

Moyenne Internet users (per 100 people)

Population, total

Indicator Name

GDP per capita (current US\$)

242 pays différents —

**Avant** 

216 pays restants

**Après** 



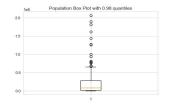
# Data Cleaning & Data Analysis

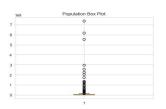
#### Analyse des Nans

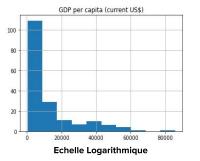
Méthode de remplissage manuel par les valeurs de la cellule voisine

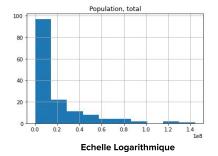
```
for ind in range(0,len(relevant indicators)):
   print(relevant indicators[ind],": \n",
         data manual[data manual['Indicator Name'] == relevant indicators[ind]].describe()," \n------\n")
Population, total :
                            2011
                                         2012
count 1.840000e+02 1.840000e+02 1.840000e+02 1.840000e+02 1.840000e+02
      2.515622e+08 2.546393e+08 2.577727e+08 2.609632e+08 2.640943e+08
      8.562833e+08 8.665048e+08 8.769007e+08 8.874179e+08 8.979575e+08
      1.053100e+04 1.062800e+04 1.072500e+04 1.081900e+04 1.090800e+04
      3.030616e+06 3.150317e+06 3.293610e+06 3.295426e+06 3.297751e+06
      1.071705e+07 1.089832e+07 1.096584e+07 1.103985e+07 1.117648e+07
75%
      5.305393e+07 5.364187e+07 5.426482e+07 5.504245e+07 5.580734e+07
      6.930657e+09 7.012844e+09 7.097401e+09 7.182860e+09 7.268986e+09
count 1.840000e+02 1.840000e+02
      2.672338e+08 2.216271e+08
      9.085239e+08 7.557216e+08
      1.100100e+04 9.230286e+03
      3.317883e+06 2.826996e+06
      1.127393e+07 9.404996e+06
75%
      5.644163e+07 4.689315e+07
     7.355220e+09 6.121138e+09
```

Tableau nominative pour chaque indicateur









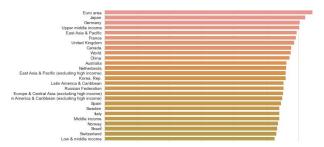
Représentant la répartition du PIB et de la Population des pays sans grandes valeurs aberrantes

# **Data Analysis**

#### Hiérarchisation des pays

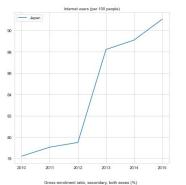
first\_test\_grade - data\_manual.reindex(columns-['Country Name','2010 Grade','2011 Grade','2012 Grade','2013 Grade','2014 Grade', first\_test\_grade = first\_test\_grade.groupby(['Country Name']).sum() first\_test\_grade.head(50)

	2010 Grade	2011 Grade	2012 Grade	2013 Grade	2014 Grade	2015 Grade
Country Name						
Afghanistan	5.692514	5.818627	5.952393	6.004232	6.039163	6.118895
Albania	7.674336	8.000684	8.262095	8.519637	8.690122	8.651935
Algeria	9.350770	9.748751	9.922564	10.100008	10.399501	10.523782
Angola	5.577156	5.805751	6.037715	6.208570	6.278020	6.184919
Antigua and Barbuda	8.105696	8.287706	8.570428	8.763152	8.991665	9.128149
Arab World	11.317227	11.695683	11.998809	12.092332	12.110746	12.110746
Argentina	11.640405	12.081448	12.300913	12.475992	12.626789	12.855434
Aruba	9.153053	9.518527	9.837922	10.033922	10.229122	10.424371
Australia	13.687727	14.003609	14.076060	14.272895	14.233225	14.184784

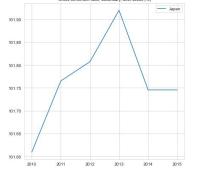


	Country Name	Country Code	Indicator Name	Indicator Code	2010	2011	2012	2013	2014	2015	Mean	CentraleSupélec
448375	Japan	JPN	GDP per capita (current US\$)	NY.GDP.PCAP.CD	4.450768e+04	4.816800e+04	4.860348e+04	4.045445e+04	3.809621e+04	3.447414e+04	3.632914e+04	
448465	Japan	JPN	Gross enrolment ratio, secondary, both sexes (%)	SE.SEC.ENRR	1.016095e+02	1.017654e+02	1.018073e+02	1.019200e+02	1.017456e+02	1.017456e+02	8.497463e+01	
448505	Japan	JPN	Internet users (per 100 people)	IT.NET.USER.P2	7.821000e+01	7.905411e+01	7.949640e+01	8.821943e+01	8.910683e+01	9.105803e+01	7.216354e+01	
449663	Japan	JPN	Population,	SP.POP.TOTL	1.280700e+08	1.278330e+08	1.276290e+08	1.274450e+08	1.272760e+08	1.271410e+08	1.093420e+08	

201	2014	2013	2012	2011	2010	
High incom	High income	High income	High income	High income	High income	1
OECD member	OECD members	OECD members	OECD members	OECD members	OECD members	2
Europe & Central Asi	Europe & Central Asia	European Union	European Union	European Union	European Union	3
North Americ	European Union	Europe & Central Asia	North America	Europe & Central Asia	North America	4
European Unio	North America	North America	Europe & Central Asia	Euro area	Euro area	5
United State	Euro area	Euro area	United States	North America	United States	6
Euro are	United States	United States	Euro area	United States	Europe & Central Asia	7
Japa	Japan	Japan	Japan	Japan	Japan	8
Upper middle incom	Upper middle income	Upper middle income	Germany	Germany	Germany	9
East Asia & Pacifi	Germany	Germany	Upper middle income	Upper middle income	United Kingdom	10
United Kingdor	United Kingdom	East Asia & Pacific	East Asia & Pacific	France	France	11
German	East Asia & Pacific	United Kingdom	France	United Kingdom	Upper middle income	12
Chin	France	France	United Kingdom	East Asia & Pacific	East Asia & Pacific	13
Worl	China	China	Canada	Canada	Canada	14
Franc	World	World	World	World	World	15
East Asia & Pacific (excludin high income	Canada	Canada	China	Netherlands	Netherlands	16
Canad	East Asia & Pacific (excluding high income)	East Asia & Pacific (excluding high income)	Australia	Australia	Korea, Rep.	17
Korea, Rep	Korea, Rep.	Australia	Netherlands	Korea, Rep.	Australia	18
Latin America & Caribbea	Europe & Central Asia (excluding high income)	Europe & Central Asia (excluding high income)	East Asia & Pacific (excluding high income)	China	Spain	19
Latin America & Caribbea (excluding high income	Latin America & Caribbean	Korea, Rep.	Korea, Rep.	East Asia & Pacific (excluding high income)	Italy	20



PARIS-SACLAY





# Hypothèse vérifiée

- 1. Valider la qualité de ce jeu de données (comporte-t-il beaucoup de données manquantes, dupliquées ?) 🗸
- 2. Décrire les informations contenues dans le jeu de données (nombre de colonnes ? nombre de lignes ?)
- 3. Sélectionner les informations qui semblent pertinentes pour répondre à la problématique (quelles sont les colonnes contenant des informations qui peuvent être utiles pour répondre à la problématique de l'entreprise ?)
- 4. Déterminer des ordres de grandeurs des indicateurs statistiques classiques pour les différentes zones géographiques et pays du monde (moyenne/médiane/écart-type par pays et par continent ou bloc géographique)



### **Conclusion**

2015	2014	2013	2012	2011	2010	
High income	High income	High income	High income	High income	High income	1
OECD members	OECD members	OECD members	OECD members	OECD members	OECD members	2
Europe & Central Asia	Europe & Central Asia	European Union	European Union	European Union	European Union	3
North America	European Union	Europe & Central Asia	North America	Europe & Central Asia	North America	4
European Union	North America	North America	Europe & Central Asia	Euro area	Euro area	5
United States	Euro area	Euro area	United States	North America	United States	6
Euro area	United States	United States	Euro area	United States	Europe & Central Asia	7
Japar	Japan	Japan	Japan	Japan	Japan	8
Upper middle income	Upper middle income	Upper middle income	Germany	Germany	Germany	9
East Asia & Pacific	Germany	Germany	Upper middle income	Upper middle income	United Kingdom	10
United Kingdom	United Kingdom	East Asia & Pacific	East Asia & Pacific	France	France	11
Germany	East Asia & Pacific	United Kingdom	France	United Kingdom	Upper middle income	12
China	France	France	United Kingdom	East Asia & Pacific	East Asia & Pacific	13
World	China	China	Canada	Canada	Canada	14
France	World	World	World	World	World	15
East Asia & Pacific (excluding high income	Canada	Canada	China	Netherlands	Netherlands	16
Canada	East Asia & Pacific (excluding high income)	East Asia & Pacific (excluding high income)	Australia	Australia	Korea, Rep.	17
Korea, Rep	Korea, Rep.	Australia	Netherlands	Korea, Rep.	Australia	18
Latin America & Caribbear	Europe & Central Asia (excluding high income)	Europe & Central Asia (excluding high income)	East Asia & Pacific (excluding high income)	China	Spain	19
Latin America & Caribbear (excluding high income	Latin America & Caribbean	Korea, Rep.	Korea, Rep.	East Asia & Pacific (excluding high income)	Italy	20

On peut observer un classement des pays et régions sur les 6 années

La Edtech peut penser s'orienter vers les pays ayant une langue commune

Suivre les pays présentant une forte évolution sur ces années.



# Merci pour votre attention !!